

LH NAUTICAL

EQUIPAMENTOS NÁUTICOS

Análises e insights

Leitura da base transacional 2020-2026

48.998 pedidos | 2.000 clientes | 24 tabelas | 433.424 registros

Documento complementar ao dashboard

Francisco Taveira

ftaveira.dev@gmail.com
ftaveira-data@outlook.com

github.com/ftaveira-data/lh-nautical-pipeline

linkedin.com/in/francisco-a-taveira

Sumário executivo

A base descreve sete anos de operação de uma varejista de equipamentos náuticos, com dois canais de venda e seis unidades. Ela sustenta análise, mas exige três decisões explícitas antes de qualquer número ser publicado. Este documento reúne os achados, separa o que é característica do negócio do que é defeito de dado, e aponta onde as conclusões mudam conforme o critério adotado.

R\$ 1,41 Bi Valor bruto somado	R\$ 1,20 Bi Receita realizada	14,8% Do valor em cancelados e rascunhos	R\$ 5,88 Mi Reembolsos em devoluções	0,42% Taxa de devolução
--	---	--	--	-----------------------------------

A conclusão que mais importa

Somar a coluna **total** sem filtrar status superestima o faturamento em 17%. Pedidos cancelados e rascunhos chegam com valor preenchido como qualquer outro, e respondem por R\$ 207,1 milhões. Não é um detalhe de arredondamento: é a diferença entre R\$ 1,41 bilhão e R\$ 1,20 bilhão.

Os três critérios que mudam o resultado

- **Status do pedido.** Incluir ou não cancelados e rascunhos altera o faturamento em 17% e reordena o ranking de clientes: filtrando apenas pedidos pagos, 7 dos 10 melhores por ticket médio mudam de posição e o primeiro colocado troca.
- **Denominador da média diária.** Ignorar os dias sem venda infla a média de forma desigual entre os dias da semana. Pelo cálculo incorreto o pior dia seria segunda-feira; pelo correto é quinta-feira.
- **Data de corte.** A base vai até 31/12/2026 e 8,7% dos pedidos têm data posterior ao momento da análise. Sem um corte declarado, o mesmo indicador muda conforme o dia em que a consulta roda.

O que este documento cobre

- 1 Confiabilidade dos dados**
Integridade estrutural, ausências que são processo e colunas que não entregam o que prometem
- 2 Leitura da operação**
Receita, canal e o ciclo do pedido, com o que cada status revela nas tabelas relacionadas
- 3 Devoluções**
Volume, motivos normalizados e taxa por categoria
- 4 O que os modelos conseguem e o que não conseguem**
Previsão de demanda e recomendação de produtos, com seus limites
- 5 Recomendações**
Ações separadas por quem consome, quem mantém e quem decide

1. Confiabilidade dos dados

A integridade estrutural é boa. Não há id duplicado, desconto maior que subtotal, data de atualização anterior à de criação, estoque negativo nem devolução anterior à compra. A aritmética fecha: **total = subtotal - desconto** nas 48.998 linhas. Os problemas estão em outro lugar.

Ausência que é processo, não defeito

Quase metade dos pedidos não tem vendedor associado. A tentação é tratar como dado faltante e preencher. A quebra por canal mostra o contrário:

Canal	Pedidos	Sem vendedor	% sem vendedor
E-commerce	34.342	24.131	70,3%
Loja física	14.656	0	0,0%

Zero por cento nas lojas físicas não acontece por acaso. Venda presencial tem vendedor, venda online não. O modelo dimensional trata isso com um membro explícito **Sem vendedor**, em vez de nulo, para que o total por vendedor feche com o total geral. O que sobra como pergunta de negócio é o inverso: 29,7% dos pedidos de e-commerce têm vendedor preenchido. Venda assistida, ou atribuição de comissão?

Colunas que não entregam o que prometem

Coluna	Situação	Consequência
stock_levels.reorder_point	100% vazia (6.054 linhas)	Não há ponto de reposição cadastrado
orders.placed_at	Idêntica a created_at em 100%	Não dá para medir o tempo até a efetivação
stock_movements.employee_id	50,3% nulo	Rastreabilidade parcial da movimentação
returns.reason	33 variações para 6 motivos	GROUP BY bruto não responde nada

Cadastro de produtos

O catálogo de 500 produtos tem um item chamado **NAO INFORMADO**, dois chamados **asdf**, um **TBD** e um **Genérico**. Quatro nomes se repetem em product_ids diferentes, o que faz qualquer análise por nome somar ou separar cadastros dependendo da escolha de quem consulta. A categoria **SEGURANÇA** está em caixa alta enquanto as outras treze usam capitalização normal.

O caso dos motivos de devolução

A coluna **reason** tem 33 valores distintos para seis motivos reais: erro de digitação ("Produto ccom defeito de fábrica"), caixa alta ("COMPRA DUPLICADA"), espaço sobrando nas pontas, espaço duplicado no meio e três formas diferentes de vazio. Um agrupamento sobre o valor bruto devolve 33 categorias e nenhuma resposta. Normalizados, restam 7, e aí o dado passa a informar:

Motivo	Devoluções	% do total
Cliente desistiu da compra	183	18,7%
Compra duplicada	167	17,0%
Item não corresponde à descrição	159	16,2%
Produto avariado no transporte	154	15,7%
Tamanho ou cor incorretos	152	15,5%
Produto com defeito de fábrica	141	14,4%
Não informado	24	2,4%

Metade das devoluções não é culpa do produto

Desistência, compra duplicada e tamanho ou cor incorretos somam **50,3%** das devoluções. São causas que nascem na jornada de compra, não no item. Defeito de fábrica responde por 14,4% e avaria no transporte por 15,7%. Na prática, melhorar descrição de produto, foto e fluxo de checkout tende a render mais do que auditar fornecedor.

A limpeza foi aplicada na camada analítica, não na tabela de origem. As duas versões convivem no modelo, nas colunas **motivo_original** e **motivo**, de modo que a transformação pode ser auditada sem sair do banco.

2. Leitura da operação

Receita e crescimento

A receita realizada cresce todos os anos, sem uma única queda, de R\$ 109,1 milhões em 2020 para R\$ 249,8 milhões em 2026. O volume de pedidos acompanha, de 3.801 para 8.721. Um crescimento tão liso não é o padrão de varejo real, e vale registrar como característica da base.

Ano	2020	2021	2022	2023	2024	2025	2026
Receita (R\$ Mi)	109,1	124,7	144,4	164,4	187,9	219,2	249,8
Pedidos	3.801	4.320	4.988	5.679	6.511	7.680	8.721

Canal

O e-commerce responde por 70% do valor, mas o ticket médio dos dois canais é praticamente idêntico: R\$ 28.746 online contra R\$ 28.607 presencial. A diferença está no volume de pedidos, não no tamanho da compra. A taxa de cancelamento também é equivalente, 10,0% contra 9,7%, o que afasta a hipótese de que o canal online gere mais arrependimento.

O ciclo do pedido

Os quatro status formam um funil coerente, e cada um tem uma assinatura verificável nas tabelas relacionadas:

Status	Pedidos	Valor	% valor	Pagamento	Nota fiscal
Pago	34.365	R\$ 985,7 Mi	70,1%	sim	sim
Confirmado	7.335	R\$ 213,6 Mi	15,2%	sim	não
Cancelado	4.847	R\$ 137,4 Mi	9,8%	sim	não
Rascunho	2.451	R\$ 69,7 Mi	5,0%	não	não

Três leituras saem dessa tabela. **Rascunho é carrinho abandonado**: nenhum dos 2.451 tem registro em payments, então não é venda perdida no meio do processo, é intenção que nunca virou transação. **Cancelado já foi pago**: os 4.847 cancelados têm pagamento associado, ou seja, são estornos, e R\$ 137,4 milhões passaram pelo caixa antes de voltar. **Confirmado não emite nota**: nota fiscal existe exclusivamente para pedidos pagos, o que deixa R\$ 213,6 milhões pagos e sem documento fiscal emitido.

Onde o dinheiro para

R\$ 213,6 milhões em pedidos confirmados e pagos aguardam emissão de nota fiscal, e R\$ 137,4 milhões foram cancelados após o pagamento. Juntos, são R\$ 351 milhões que entraram no fluxo e não se converteram em receita documentada. Se isso é etapa normal do processo ou gargalo de faturamento é a pergunta a levar para a operação.

3. Devoluções

São 980 devoluções cobrindo 1.384 itens, com R\$ 5,88 milhões reembolsados. A taxa sobre itens vendidos é de 0,42%, baixa para varejo. O prazo entre a compra e a devolução vai de 7 a 44 dias, com mediana de 23, o que sugere uma política de devolução com janela definida sendo respeitada.

Reembolso e troca são coisas diferentes

Das 1.384 linhas devolvidas, 1.024 são reembolso e 360 são troca. As trocas têm valor de reembolso zero, por definição. Qualquer ranking de prejuízo por produto que não separe os dois vai exibir itens com R\$ 0 no topo da lista de devoluções, o que confunde mais do que informa.

A taxa por categoria não aponta culpado

Iluminação lidera com 0,665% e Equipamentos fecha com 0,441%. A distância entre a primeira e a última é de 0,22 ponto percentual, distribuída de forma contínua pelas quatorze categorias. Não há categoria fora da curva, e nenhuma ação de qualidade se justifica com base nesse recorte.

Categoria	Itens vendidos	Devolvidos	Taxa
Iluminação	54.283	361	0,665%
Cabos	47.457	307	0,647%
Eletrônica Náutica	66.618	431	0,647%
Acessórios de Convés	43.883	270	0,615%
Hélices	83.132	497	0,598%
Manutenção	58.269	277	0,475%
Equipamentos	61.460	271	0,441%

Primeiras cinco e últimas duas colocadas, de quatorze categorias.

O que isso significa para o estoque

Com 0,42% de devolução e prazo mediano de 23 dias, o volume que retorna é previsível e não representa risco operacional. O problema de ruptura descrito no cenário não vem das devoluções: vem da previsão de demanda, tratada na próxima seção.

4. O que os modelos conseguem e o que não conseguem

Previsão de demanda

Uma média móvel de três meses treinada até dezembro de 2025 previu 116 unidades para o primeiro trimestre de 2026. O realizado foi 207. O erro médio absoluto foi de 30,33 unidades por mês, contra uma média realizada de 69, ou seja, 44% de erro.

A causa não é a escolha da janela, é a natureza do método. A série tem tendência forte, com o primeiro trimestre saindo de 166 unidades em 2025 para 207 em 2026, e média móvel por construção reproduz o patamar anterior. Um dezembro atípico, 22 unidades contra uma média histórica de 44,9 para o mês, agravou o quadro ao puxar a base do cálculo para baixo justamente quando a série acelerava.

Consequência prática

Subestimar demanda em 44% significa comprar menos do que se vende. Para um item de giro alto, é ruptura de estoque. Antes de usar previsão para decisão de compra, o modelo precisa de componente de tendência, ou no mínimo de comparação com o mesmo período do ano anterior.

Recomendação de produtos

A matriz de 2.000 clientes por 500 produtos tem densidade de 13,6%: o cliente médio comprou cerca de 68 produtos distintos ao longo de sete anos. Sobre ela, a similaridade de cosseno entre todos os pares varia de 0,007 a 0,279, com mediana de 0,132. É uma distribuição estreita, sem nenhum par que se destaque.

Para o produto de referência, os três primeiros colocados ficam a menos de 0,001 um do outro, separados por três clientes em 397, e são de categorias completamente diferentes:

Produto recomendado	Similaridade	Clientes em comum	Posição em vendas
Motor de Popa 5331	0,2566	106	5º de 500
Cabo Náutico 2105	0,2562	103	45º de 500
Vela Mestra 1913	0,2558	100	110º de 500

Três dos cinco recomendados estão entre os seis produtos com mais compradores da loja, enquanto o produto de referência é apenas o 75º. O ranking está capturando popularidade tanto quanto afinidade. A conclusão honesta é que **não existe padrão de compra conjunta detectável nesta base**. O método está correto; o dado é que não tem sinal.

Uma limitação de grão que vale corrigir

A matriz registra que o cliente comprou dois produtos em algum momento dos últimos sete anos, não que os levou na mesma compra. Para recomendação de carrinho, que é o caso de uso típico, uma matriz pedido por produto responderia melhor: hoje, duas compras separadas por três anos contam igual a duas no mesmo carrinho.

5. Recomendações

Para quem consome os números

- Publicar sempre o critério de status junto do valor. **Faturamento** e **receita realizada** diferem em R\$ 207 milhões e não devem circular com o mesmo nome.
- Declarar a data de corte em qualquer análise temporal, dado que 8,7% dos pedidos têm data futura.
- Tratar média diária sempre contra o calendário completo, nunca contra os dias que aparecem na tabela de vendas.

Para quem mantém os dados

- Normalizar **returns.reason** na origem, com lista fechada de valores. A limpeza hoje vive na camada analítica e precisa ser mantida a cada carga.
- Definir se **placed_at** e **created_at** devem divergir. Hoje são idênticas nas 48.998 linhas, o que desperdiça uma métrica de processo.
- Preencher ou remover **stock_levels.reorder_point**. Coluna 100% vazia em 6.054 linhas ocupa espaço no schema e sugere um controle que não existe.
- Limpar o cadastro de produtos: NAO INFORMADO, asdf, TBD, Genérico e quatro nomes duplicados em ids diferentes.

Para quem decide

- **Não fechar loja com base no dia da semana.** O pior dia, quinta-feira com R\$ 157.154 de média, e o melhor, quarta-feira com R\$ 173.605, diferem 10%, e os três piores ficam dentro de 0,7% um do outro.
- **Investigar os R\$ 213,6 milhões pagos sem nota fiscal.** É o maior valor parado identificado na base.
- **Priorizar descrição de produto sobre auditoria de fornecedor.** Metade das devoluções vem da jornada de compra, não de defeito.
- **Não usar a recomendação atual em produção.** Ela reproduz popularidade. Refazer no grão do pedido antes de qualquer teste com cliente.

Nota de método

Todos os números deste documento foram extraídos das 24 tabelas de origem e conferidos contra o modelo dimensional publicado no dashboard. As decisões de limpeza estão documentadas no cabeçalho de cada view, e as versões original e tratada convivem no modelo para que qualquer transformação possa ser auditada.

O ambiente sobe com Docker e o pipeline é reproduzível de ponta a ponta: inferência de schema a partir dos CSVs, carga em PostgreSQL, camada dimensional em views e relatório em Power BI. As instruções de execução estão no README do repositório.

Contato e código

Repositório	github.com/ftaveira-data/lh-nautical-pipeline
LinkedIn	linkedin.com/in/francisco-a-taveira
E-mail	ftaveira.dev@gmail.com · ftaveira-data@outlook.com